



Dans ce cours, vous comprendrez comment installer et configurer Hadoop pour Windows

Étapes pour installer Hadoop

- Installer JavaJDK 1.8
- Téléchargez Hadoop et extrayez-le et placez-le sous le lecteur C
- Définir le chemin dans les variables d'environnement
- Fichiers de configuration sous le répertoire Hadoop
- Créer un dossier datanode et namenode sous le répertoire de données
- Modifier les fichiers HDFS et YARN
- Définir l'environnement Java Home dans l'environnement Hadoop
- Configuration terminée. Testez en exécutant start-all.cmd

Il existe deux manières d'installer Hadoop, c'est-à-dire

- Nœud unique
- Multi nœud

Un cluster à nœud unique signifie qu'un seul DataNode s'exécute et configure tous les NameNode, DataNode, ResourceManager et NodeManager sur une seule machine.

Ceci est utilisé à des fins d'étude et de test.

- Donc, pour tester si les TP ont planifié tous les processus tels que la collecte, l'agrégation, le stockage et le traitement des données dans un ordre approprié, nous utilisons un cluster à nœud unique.
- Il peut facilement et efficacement tester le flux de travail séquentiel dans un environnement plus petit par rapport aux grands environnements qui contiennent des téraoctets de données réparties sur des centaines de machines.

Dans un cluster multi-nœuds, plusieurs DataNode sont en cours d'exécution et chaque DataNode s'exécute sur différentes machines. Le cluster multi-nœuds est pratiquement utilisé dans les organisations pour analyser le Big Data. En temps réel lorsque l'on traite des pétaoctets de données, celles-ci doivent être réparties sur des centaines de machines pour être traitées. Ainsi, nous utilisons ici un cluster multi-nœuds.

Configuration d'un cluster Hadoop à nœud unique

Prérequis pour installer Hadoop sur Windows

- *VIRTUAL BOX (Pour Linux)* : il sert à installer le système d'exploitation dessus.
- *SYSTÈME D'EXPLOITATION* : Vous pouvez installer Hadoop sur des systèmes d'exploitation basés sur Windows ou Linux. Ubuntu et CentOS sont très couramment utilisés.
- *JAVA* : Vous devez installer le package Java 8 sur votre système.
- *HADOOP* : Vous avez besoin de la dernière version stable de Hadoop

1. Installer Java

– Lien Java JDK à télécharger

<https://www.oracle.com/java/technologies/javase-jdk8-downloads.html>

– extraire et installer Java dans C:\Java

– ouvrez cmd et tapez -> javac -version

 Invite de commandes

```
Microsoft Windows [version 10.0.19044.1645]
(c) Microsoft Corporation. Tous droits réservés.


C:\Users\DSIGPIP>javac -version
javac 1.8.0_333
```


2. Télécharger Hadoop

– <https://www.apache.org/dyn/closer.cgi/hadoop/common/hadoop-3.3.1/hadoop-3.3.1.tar.gz>

– extraire vers C:\Hadoop

3. Définissez le chemin de la variable d'environnement JAVA_HOME
4. Définissez le chemin de la variable d'environnement HADOOP_HOME





The image is a screenshot of the Windows Control Panel, specifically the 'System' page. On the left sidebar, under 'Control Panel Home', there are four links: 'Device Manager', 'Remote settings', 'System protection', and 'Advanced system settings'. The 'Advanced system settings' link is highlighted with a red rectangular box. The main content area on the right is titled 'View basic information about your computer'. It contains several sections: 'Windows edition' showing 'Windows 10 Home Single Language' and '© 2019 Microsoft Corporation. All rights reserved'; 'System' information including 'Manufacturer: ASUSTek Computer Inc.', 'Processor: Intel(R) Core(TM) i7-8665U CPU @ 2.10GHz', 'Installed memory (RAM): 8.00 GB (7.89 GB usable)', 'System type: 64-bit Operating System', and 'Pen and Touch: No Pen or Touchscreen'; 'ASUSTek Computer Inc. support' with a link to 'Online support'; and 'Computer name, domain, and workgroup settings' showing 'Computer name: DESKTOP-475FC...', 'Full computer name: DESKTOP-475FC...', 'Computer description: ...', and 'Workgroup: WORKGROUP'.

Control Panel Home

- Device Manager
- Remote settings
- System protection
- Advanced system settings**

View basic information about your computer

Windows edition

Windows 10 Home Single Language

© 2019 Microsoft Corporation. All rights reserved.

System

Manufacturer: ASUSTek Computer Inc.

Processor: Intel(R) Core(TM) i7-8665U CPU @ 2.10GHz

Installed memory (RAM): 8.00 GB (7.89 GB usable)

System type: 64-bit Operating System

Pen and Touch: No Pen or Touchscreen

ASUSTek Computer Inc. support

Website: [Online support](#)


Computer name, domain, and workgroup settings


Computer name: DESKTOP-475FC...


Full computer name: DESKTOP-475FC...

Computer description: ...

Workgroup: WORKGROUP







Testez en tapant :

```
Invite de commandes
Microsoft Windows [version 10.0.19044.1645]
(c) Microsoft Corporation. Tous droits réservés.

C:\Users\DSIGPIP>javac -version
javac 1.8.0_333

C:\Users\DSIGPIP>hadoop version
Hadoop 3.3.1
Source code repository https://github.com/apache/hadoop.git -r a3b9c37a397ad4188041dd80621bdeefc46885f2
Compiled by ubuntu on 2021-06-15T05:13Z
Compiled with protoc 3.7.1
From source with checksum 88a4ddb2299aca054416d6b7f81ca55
This command was run using /C:/hadoop-3.3.1/share/hadoop/common/hadoop-common-3.3.1.jar

C:\Users\DSIGPIP>
```

5. Configurations

Editez le fichier C:/Hadoop-3.3.1/etc/hadoop/core-site.xml, collez le code xml dans le dossier et enregistrez

```
<configuration>
```

```
<property>
```

```
<name>fs.default.name</name>
```

```
<value>hdfs://localhost:9000</value>
```

```
</property>
```

```
</configuration>
```

=====

Editez le fichier C:/ Hadoop-3.3.1/etc/hadoop/mapred-site.xml, collez le code xml et enregistrez ce fichier.

```
<configuration>
```

```
<property>
```

```
<name>mapreduce.framework.name</name>
```

```
<value>yarn</value>
```



```
</property>
```

```
</configuration>
```

=====

Créez le dossier "data" sous "C:\Hadoop-3.3.1"

Créez le dossier "datanode" sous "C:\Hadoop-3.3.1\data"

Créez le dossier "namenode" sous "C:\Hadoop-3.3.1\data"

=====

Editez le fichier C:\Hadoop-3.3.1/etc/hadoop/hdfs-site.xml, collez le code xml et enregistrez ce fichier.

```
<configuration>
```

```
<property>
```

```
<name>dfs.replication</name>
```

```
<value>1</value>
```

```
</property>
```

```
<property>
```

```
<name>dfs.namenode.name.dir</name>
```

```
<value>/hadoop-3.3.1/data/namenode</value>
```

```
</property>
```

```
<property>
```

```
<name>dfs.datanode.data.dir</name>
```

```
<value>/hadoop-3.3.1/data/datanode</value>
```

```
</property>
```

```
</configuration>
```

=====

Editez le fichier C:/Hadoop-3.3.1/etc/hadoop/yarn-site.xml, collez le code xml et enregistrez ce fichier.

```
<configuration>
```

```
  <property>
```

```
    <name>yarn.nodemanager.aux-services</name>
```

```
    <value>mapreduce_shuffle</value>
```

```
  </property>
```

```
  <property>
```

```
    <name>yarn.nodemanager.auxservices.mapreduce.shuffle.class</name>
```

```
    <value>org.apache.hadoop.mapred.ShuffleHandler</value>
```

```
  </property>
```

```
</configuration>
```

```
=====
```

Modifier le fichier C:/Hadoop-3.3.1/etc/hadoop/hadoop-env.cmd :

```
set JAVA_HOME==%JAVA_HOME%" en set JAVA_HOME=C:\Java\jdk1.8.0_333
```

```
=====
```

6. Configurations Hadoop

Télécharger

https://github.com/brainmentorspvtltd/BigData_RDE/blob/master/Hadoop%20Configuration.zip

ou (pour hadoop 3)


<https://github.com/s911415/apache-hadoop-3.1.0-winutils>

– Copier le dossier bin et remplacer le dossier bin existant dans

C:\Hadoop-3.3.1\bin

– Formater le NameNode

– Ouvrez cmd et tapez la commande « hdfs namenode –format »



```
Invite de commandes
Microsoft Windows [version 10.0.19044.1645]
(c) Microsoft Corporation. Tous droits réservés.

C:\Users\DSIGPIP>hdfs namenode -format
2022-05-28 16:03:36,748 INFO namenode.NameNode: STARTUP_MSG:
/*****
STARTUP_MSG: Starting NameNode
STARTUP_MSG: host = DESKTOP-D7STSV6/192.168.43.17
STARTUP_MSG: args = [-format]
STARTUP_MSG: version = 3.3.1
STARTUP_MSG: classpath = C:\hadoop-3.3.1\etc\hadoop;C:\hadoop-3.3.1\share\hadoop\common;C:\hadoop-3.3.1\share\hadoop\com
mon\lib\accessors-smart-2.4.2.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\animal-sniffer-annotations-1.17.jar;C:\hadoo
p-3.3.1\share\hadoop\common\lib\asm-5.0.4.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\audience-annotations-0.5.0.jar;C:\h
adoop-3.3.1\share\hadoop\common\lib\avro-1.7.7.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\checker-qual-2.5.2.jar;C:\ha
adoop-3.3.1\share\hadoop\common\lib\commons-beanutils-1.9.4.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\commons-cli-1.2.j
ar;C:\hadoop-3.3.1\share\hadoop\common\lib\commons-codec-1.11.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\commons-collec
tions-3.2.2.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\commons-compress-1.19.jar;C:\hadoop-3.3.1\share\hadoop\common\li
b\commons-configuration2-2.1.1.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\commons-daemon-1.0.13.jar;C:\hadoop-3.3.1\sha
re\hadoop\common\lib\commons-io-2.8.0.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\commons-lang3-3.7.jar;C:\hadoop-3.3.1\
share\hadoop\common\lib\commons-logging-1.1.3.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\commons-math3-3.1.1.jar;C:\had
oop-3.3.1\share\hadoop\common\lib\commons-net-3.6.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\commons-text-1.4.jar;C:\ha
adoop-3.3.1\share\hadoop\common\lib\curator-client-4.2.0.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\curator-framework-4.
2.0.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\curator-recipes-4.2.0.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\dnsjav
a-2.1.7.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\failureaccess-1.0.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\gson-2.
2.4.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\guava-27.0-jre.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\hadoop-annot
ations-3.3.1.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\hadoop-auth-3.3.1.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\h
adoop-shaded-guava-1.1.1.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\hadoop-shaded-protobuf_3_7-1.1.1.jar;C:\hadoop-3.3.
1\share\hadoop\common\lib\htrace-core4-4.1.0-incubating.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\httpclient-4.5.13.ja
r;C:\hadoop-3.3.1\share\hadoop\common\lib\httpcore-4.4.13.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\j2objc-annotations
-1.1.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\jackson-annotations-2.10.5.jar;C:\hadoop-3.3.1\share\hadoop\common\lib\j
```

7. Tester

– Ouvrez cmd et changez de répertoire en C:\Hadoop- 3.3.1 \sbin

– tapez : start-all.cmd

(Ou vous pouvez commencer comme ça)

– Démarrer namenode et datanode avec cette commande

– tapez : start-dfs.cmd

– Démarrer yarn via cette commande

– tapez : start-yarn.cmd


Assurez-vous que ces applications sont en cours d'exécution

– NameNode de Hadoop

– DataNode de Hadoop

– Gestionnaire de ressources YARN : ResourceManager

– Gestionnaire de nœuds YARN : NodeManager



The screenshot shows a Windows Command Prompt window titled "Invite de commandes". The text inside the window is as follows:

```
Microsoft Windows [version 10.0.19044.1645]  
(c) Microsoft Corporation. Tous droits réservés.  
  
C:\Users\DSIGPIP>jps  
5184 NameNode  
7296  
12580 DataNode  
15688 NodeManager  
20120 ResourceManager  
7416 Jps  
  
C:\Users\DSIGPIP>
```

The window has standard Windows window controls (minimize, maximize, close) in the top right corner. The text "Activer Windows" is partially visible at the bottom right of the window.

Ouvrez : <http://localhost:8088>

← → ↻

localhost:8088/cluster



All Applications

Cluster

About

Nodes

Node Labels

Applications

NEW

NEW SAVING

SUBMITTED

ACCEPTED

RUNNING

FINISHED

FAILED

KILLED

Scheduler

Tools

Cluster Metrics

Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	Memory Used	Memory Total
0	0	0	0	0	0 B	8 GB

Cluster Nodes Metrics

Active Nodes	Decommissioning Nodes	Decommissioned Nodes	Lost Nodes	Unhealthy Nodes
1	0	0	0	0

Scheduler Metrics


Scheduler Type	Scheduling Resource Type	Minimum Allocation	Maximum Allocation
Capacity Scheduler	[MEMORY]	<memory:1024, vCores:1>	<memory:8192, vCores:1>

Show 20 entries

ID	User	Name	Application Type	Queue	Application Priority	StartTime	FinishTime	State	FinalStatus	Running Containers	Allocated CPU VCore
No data available in table											

Showing 0 to 0 of 0 entries

Ouvrez : <http://localhost:9870>



Overview 'localhost:9000' (✓active)

Started:	Sun Nov 08 16:53:46 +0530 2020
Version:	3.3.0, [REDACTED]
Compiled:	Tue Jul 07 00:14:00 +0530 2020 by brahma fr
Cluster ID:	C [REDACTED]
Block Pool ID:	B [REDACTED]

Summary

=====

Hadoop installed Successfully.....

=====

Exemple : Map-Reduce wordcount

-Créer un fichier nommé « data.txt » contenant des données dans le lecteur C.

-Créer un repertoire nommé « input_dir » dans HDFS :

```
hadoop fs -mkdir /input_dir
```

-Copier le fichier « data.txt » dans le repertoire « input_dir » de HDFS :

```
hadoop fs -put C:/data.txt /input_dir
```

-Visualiser les droits sur le fichier « data.txt » dans HDFS :

```
hadoop dfs -ls /input_dir/data.txt
```

```
Ou hdfs dfs -ls /input_dir/data.txt
```

-Visualiser en console le fichier « data.txt » dans HDFS :

```
hadoop fs -cat /input_dir/data.txt
```

- Executer mapReduce sur le fichier « data.txt » de HDFS :

```
hadoop jar C:/hadoop-3.3.1/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.1.jar wordcount /input_dir /output_dir
```