

Big Data



Chapitre 1

Introduction à Big Data



BIG DATA: Définition

- La notion de Big Data est un concept s'étant popularisé en 2012 pour traduire le fait que les entreprises sont confrontées à des volumes de données à traiter de plus en plus considérables et présentant un fort enjeux commercial et marketing.
- Ces Grosses Données en deviennent difficiles à travailler avec des outils classiques de gestion de base de données.
- Il s'agit donc d'un ensemble de **technologies, d'architecture, d'outils** et de **procédures** permettant à une organisation de **très rapidement capter, traiter et analyser de larges quantités et contenus hétérogènes et changeants**, et d'en extraire les **informations pertinentes** à un **coût accessible**.

BIG DATA: Caractéristiques

- **COUVERTURE DE CINQ DIMENSIONS - 5Vs (1/2)**

- Gartner (2001) – 3Vs



- IBM (2012) – 4Vs



- 2015 : encore plus de V



BIG DATA: Caractéristiques


- **COUVERTURE DE CINQ DIMENSIONS - 5Vs (2/2)**

- 2016 : 7V ?

VARIABILITÉ

VISUALISATION

- 2017 : 10V ?




BIG DATA: Caractéristiques

- **COUVERTURE DE CINQ DIMENSIONS - 5Vs (1/7)**

- **Volume (1/2)**

- Croissance sans cesse des données à gérer de tout type, souvent en teraoctets voir en petaoctets.
 - Chaque jour, 2.5 trillions d'octets de données sont générées.
 - **90% des données créées dans le monde l'ont été au cours des 2 dernières années (2014).**
 - Prévission d'une croissance de 800% des quantités de données à traiter d'ici à 5 ans.



BIG DATA: Caractéristiques

• COUVERTURE DE CINQ DIMENSIONS - 5Vs (2/7)

– Volume (2/2)

- 4,4 zettaoctets de données
= 4,4 trillion de gigaoctets
- En 2013, il y a autant de données que les étoiles connues dans tout l'univers.
- 44 zettaoctets de données
= 44 milliards gigaoctets
- 62 fois le nombre de tous les sables dans toutes les plages de la terre.

octets

1 Mégaoctet = 10^6 octets

1 Gigaoctet = 10^9 octets

1 Téraoctet = 10^{12} octets

1 Pétaoctet = 10^{15} octets

1 Exaoctet = 10^{18} octets

1 Zettaoctet = 10^{21} octets

40
zettaoctets
de données
en 2020

50
milliards
d'objets connectés
à la même date

BIG DATA: Caractéristiques

• COUVERTURE DE CINQ DIMENSIONS - 5Vs (4/7)

– Vitesse (Velocity)

- Utilisation des données en temps réel (pour la détection de fraudes, analyse des données, ...).
 - Fait référence à la vitesse à laquelle de nouvelles données sont générées et la vitesse à laquelle les données sont traitées par le système pour être bien analysées.
 - La technologie nous permet maintenant d'analyser les données pendant qu'elles sont générées, sans jamais mettre en bases de données.
-
- Streaming Data
 - des centaines par seconde
 - 100 Capteurs
 - dans chaque voiture moderne pour la surveillance



BIG DATA: Caractéristiques

• COUVERTURE DE CINQ DIMENSIONS - 5Vs (5/7)

– Véracité

- Fait référence à la qualité de la fiabilité et la confiance des données.
- Données bruitées, imprécises, prédictives, ...
- La génération des données par Spambots est un exemple digne de confiance.
 - L'élection présidentielle de 2012 au Mexique avec de faux comptes Twitter.
- DES MILLIONS DE DOLLARS \$ PAR AN
 - Ce que la pauvre qualité des données coute pour l'économie des Etats-Unis.
- 1 à 3 CHEFS D'ENTREPRISE
 - Ne font pas confiance à l'information qu'ils utilisent.



BIG DATA: Caractéristiques

• COUVERTURE DE CINQ DIMENSIONS - 5Vs (6/7)


– Valeur

- La démarche Big Data n'a de sens que pour atteindre des objectifs stratégiques de **création de valeur** pour les clients et pour l'entreprise; dans tous les domaines d'activité : commerce, industrie, services ...
- Le succès d'un projet Big Data n'a d'intérêt aux utilisateurs que s'il **apporte de la valeur ajoutée** et de nouvelles connaissances.




BIG DATA: Caractéristiques

- **COUVERTURE DE CINQ DIMENSIONS - 5Vs (7/7)**



BIG DATA: Généralités

- **DIVERSITE ET VOLUME DES SOURCES DE DONNEES (1/4)**
Une minute sur internet en 2016 ?



BIG DATA: Généralités

• DIVERSITE ET VOLUME DES SOURCES DE DONNEES (2/4)

2016

facebook Community Update

4.27.2016



1.65 Billion
on Facebook each month



1 Billion
on WhatsApp each month



900 Million
on Messenger each month



400 Million
on Instagram each month

LIVE

Live Video
Launched worldwide



Connectivity
25 million connected
via Internet.org



Artificial Intelligence
Access for the blind
and visually impaired



Oculus Rift
Shipped with 50+
games and apps

Introduced Reactions



2017

facebook

Community Update

7.26.2017

Bringing the world closer together



2 Billion
on Facebook each month



100 Million
are members of meaningful groups



250 Million
use Stories each day



2 Billion
messages sent between
people and businesses
each month



250 Million
use Status each day



Connectivity
Aquila's second flight



VR / AR
Launched Live from Spaces

BIG DATA: Généralités


• DIVERSITE ET VOLUME DES SOURCES DE DONNEES (3/4)

– Outils numériques plus performants et plus connectés:
ordinateurs et smartphones



– Open Data

- Réseaux sociaux: facebook
- Données d'administrations publiques




– Internet des Objets

- RFID (cartes de transport, codes bar, ...)
- Ericsson a estimé le nombre d'objets connectés dans le monde à 50 milliards en 2020 (12 milliards en 2013)

BIG DATA: Généralités


• DIVERSITE ET VOLUME DES SOURCES DE DONNEES (4/4)



Source: Contents of above graphic created in partnership with Teradata, Inc.

BIG DATA: Généralités

- **Business Intelligence (BI)**



BIG DATA: Généralités

- Quel est le problème posé par ces énormes quantités de données?
 - Auparavant, quand les systèmes d'application de gestion de base de données ont été réalisés, ils ont été construits avec une **échelle à l'esprit** (limité). Même les organisations **n'ont pas été préparées à l'échelle** que nous produisons aujourd'hui.
 - Comme les exigences de ces organisations ont augmenté au fil du temps, ils doivent repenser et réinvestir dans l'infrastructure. Actuellement, le **coût** des ressources impliquées dans **l'extension de l'infrastructure**, **s'augmente** avec un facteur **exponentiel**.
 - De plus, il y aurait une **limitation** sur les différents facteurs tels que la **taille** de la machine, **CPU**, **RAM**, etc. qui peuvent être mis à l'échelle (scaled up). Ces systèmes **traditionnels** ne seraient pas en mesure de soutenir l'échelle requise par la plupart des entreprises.

BIG DATA: Généralités

- **ADAPTABILITE**

- Dans ce nouveau contexte, les **méthodes de traitement de ces données** (capture, stockage, recherche, partage, analyse, visualisation) **doivent être redéfinies** car l'ensemble de ces données deviennent **difficilement manipulables** par les outils classiques.



BIG DATA: Généralités

- **Comment le Big Data gère ces situations complexes? (1/3)**
 - La plupart des outils et des frameworks de Big Data sont construits en gardant à l'esprit les caractéristiques suivantes :
 - **La distribution des données:** Le grand ensemble de données est divisé en morceaux ou en petits blocs et réparti sur un nombre N de nœuds ou de machines. Ainsi les données sont réparties sur plusieurs nœuds et sont prêtes au traitement parallèle. Dans le monde du Big Data, ce type de distribution des données est réalisé à l'aide d'un Système de Fichiers Distribués - DFS (Distributed File System).




BIG DATA: Généralités

- **Comment le Big Data gère ces situations complexes? (2/3)**
 - **Le traitement en parallèle :** Les données distribuées obtiennent la puissance de N nombre de serveurs et de machines dont les données résident. Ces serveurs travaillent en parallèle pour le traitement et l'analyse. Après le traitement, les données sont fusionnées pour le résultat final recherché. (Actuellement ce processus est réalisé par MapReduce de Google qui sera détaillé dans une section ultérieure).
 - **La tolérance aux pannes:** En général, nous gardons la réplique d'un seul bloc (ou chunk) de données plus qu'une fois. Par conséquent, même si l'un des serveurs ou des machines est complètement en panne, nous pouvons obtenir nos données à partir d'une autre machine ou d'un autre « data center ». Encore une fois, nous pouvons penser que la réplication de données pourrait coûter beaucoup d'espace. Mais voici le quatrième point de la rescousse.

BIG DATA: Généralités

- **Comment le Big Data gère ces situations complexes? (3/3)**

- **L'utilisation de matériel standard** : La plupart des outils et des frameworks Big Data ont besoin du matériel standard pour leur travail. Donc nous n'avons pas besoin de matériel spécialisé avec un conteneur spécial des données « RAID ». Cela réduit le coût de l'infrastructure totale.
- **Flexibilité, évolutivité et scalabilité** : Il est assez facile d'ajouter de plus en plus de nœuds dans le cluster quand la demande pour l'espace augmente. De plus, la façon dont les architectures de ces frameworks sont faites, convient très bien le scénario de Big Data.



BIG DATA: Généralités

- Exemple Simple (1/4)

- Analyser une data set de 1TB

```
ABCSE,B7J,2008-10-28,6.48,6.74,6.22,6.72,44300,5.79
ABCSE,B7J,2008-10-27,6.21,6.78,6.21,6.40,55200,5.51
ABCSE,B7J,2008-10-24,6.39,6.66,6.21,6.40,67400,5.51
ABCSE,B7J,2008-10-23,6.95,6.95,6.50,6.59,59400,5.68
ABCSE,B7J,2008-10-22,6.92,7.17,6.80,6.80,55300,5.86
ABCSE,B7J,2008-10-21,7.20,7.30,7.10,7.10,54400,6.11
ABCSE,B7J,2008-10-20,6.94,7.31,6.94,7.12,45700,6.13
ABCSE,B7J,2008-10-17,6.43,6.93,6.42,6.90,57700,5.94
ABCSE,B7J,2008-10-16,6.61,6.69,6.21,6.53,83200,5.62
ABCSE,B7J,2008-10-15,6.84,6.90,6.36,6.36,78900,5.48
ABCSE,B7J,2008-10-14,7.15,7.32,6.93,6.96,74700,5.99
ABCSE,B7J,2008-10-13,6.00,6.57,6.00,6.57,75700,5.66
ABCSE,B7J,2008-10-10,5.05,5.72,4.79,5.72,158400,4.93
ABCSE,B7J,2008-10-09,6.30,6.41,6.00,6.02,140500,5.18
ABCSE,B7J,2008-10-08,5.60,6.47,5.60,6.28,292000,5.41
ABCSE,B7J,2008-10-07,7.59,7.59,6.66,6.69,89900,5.76
ABCSE,B7J,2008-10-06,7.83,7.90,7.00,7.40,159600,6.37
```

BIG DATA: Généralités

- Exemple Simple (2/4)

- Temps d'accès



Average Data Access Rate ~122 MB/sec

1 TB file will take 2 1/2 hours to read from disk

1 Sec - 122 MB
x Secs - 1048576 MB (1 TB)

$x = 1048576 / 122 = 8595$ secs
2 hr 22 mins

Activer
Accédez à

BIG DATA: Généralités

- **Exemple Simple (3/4)**

Temps d'accès (lecture) $> 2h$

+

Temps de calcul $\sim 1h$

+


Bande passante du réseau etc

$> 3h$

BIG DATA: Généralités

- **Exemple Simple (4/4)**

- Division d'un fichier de 1TB en 100 blocs égaux
- Lecture Parallèle



Temps de lecture = $150 \text{ min} / 100 < 2 \text{ min}$

Temps de calcul = $60 \text{ min} / 100 < 1 \text{ min}$

BIG DATA: Généralités


• PERSPECTIVES ET DOMAINES D'APPLICATION

- Les perspectives d'utilisation de ces données sont énormes, notamment pour l'analyse d'opinions politiques, de tendance industrielles, la génomique, la lutte contre la criminalité et la fraude, les méthodes de marketing publicitaire et de vente etc ...



BIG DATA: Généralités

- Cas d'utilisation : Santé (1/2)



BIG DATA: Généralités

- **Cas d'utilisation : Santé (2/2)**

- Analyse des données globales des patients et des résultats pour comparer l'efficacité des différentes interventions.
- Analyse des résultats de santé d'une population pour prévoir les maladies et les épidémies, savoir les causes environnementales et prendre les prévention nécessaire dans les stages primaires.
- Déploiement de systèmes d'aide à la décision clinique pour améliorer l'efficacité et la qualité des opérations.
- Télésurveillance des patients. La collecte de données pour les patients souffrants de maladies chroniques et l'analyse des données résultant pour surveiller la conformité et pour améliorer les futures options de médicaments et de traitement.

BIG DATA: Généralités

- **Cas d'utilisation : Marketing (1/2)**

- Plus d'intelligence pour plus de ventes.
- **Analyse prédictive** : En analysant l'historique des achats du client ou les fichiers Logs qui contiennent les pages visitées, l'entreprise peut prévoir ce que le client cherche et les mettre dans les zones des offres et publicités afin d'augmenter les achats.
- **Analyse des sentiments** : De Nombreuses sociétés utilisent les échanges sur les réseaux sociaux comme le reflet de l'opinion publique. Celle-ci devient une nouvelle source d'informations en temps réel directement fournie par le consommateur. Les questions d'e-réputation « à quoi est associée mon image ? » ou « comment est accueilli le nouveau produit que je viens de lancer ? » peuvent être analysées avec ces données. Le Big Data permet de prendre le pouls quasiment en direct, mesurer l'impact de sa marque, savoir comment est perçue la société par le public et anticiper les mauvaises critiques.

BIG DATA: Généralités


- **Cas d'utilisation : Marketing (2/2)**

- **Analyse des comportements** : L'analyse du comportement des clients en magasin permet d'améliorer l'aménagement du magasin, le mix produit et la disposition des produits dans les rayons et sur les étagères. Les dernières innovations ont également permis de suivre les habitudes d'achat (compter le nombre de pas effectués et le temps passé dans chaque rayon du magasin), géolocaliser en temps réel les clients,.... Les données issues des tickets de caisse, captées depuis longtemps, peuvent maintenant être analysées et révèlent les habitudes d'achat des clients.



BIG DATA: Généralités

- Cas d'utilisation : Analyse de tweets en temps réel



BIG DATA: Généralités

- **Cas d'utilisation : Politique**

- L'analyse de Big Data a joué un rôle important dans la campagne de ré-élection de Barack Obama, notamment pour analyser les opinions politiques de la population.
- Depuis l'année 2012, le Département de la défense américain investit annuellement sur les projets de Big Data plus de 250 millions de dollars.
- Le gouvernement américain possède six des dix plus puissants supercalculateurs de la planète.
- La National Security Agency est actuellement en train de construire le Utah Data Center. Une fois terminé, ce data center pourra supporter des yottaoctets d'information collectés par la NSA sur internet.
- En 2014, SIGMA conseil a utilisé le Big Data pour donner l'estimation du résultat de vote préliminaire en Tunisie.

BIG DATA: Généralités

- **Cas d'utilisation : Sport (1/2)**

- La première source de données recueillie s'appuie sur des capteurs intégrés aux protège-tibias ou aux chaussures. Ces minuscules composants remontent des informations biométriques sur les joueurs :
 - la distance parcourue
 - les vitesses en sprint
 - les accélérations
 - le nombre de ballons touchés
 - le rythme cardiaque, etc.
- A terme et quand l'analyse en temps réel sera réellement possible, on peut très bien imaginer qu'une alerte remonte lorsqu'un joueur fatigue afin que l'entraîneur le remplace.



BIG DATA: Généralités

- **Cas d'utilisation : Sport (2/2)**

- Une deuxième source de récolte de données provient de caméras installées en hauteur autour du terrain. Tous les déplacements des joueurs et leurs positions les uns par rapport aux autres sont ainsi filmés et enregistrés. Lors de son débriefing, le tacticien peut ainsi comparer plusieurs fois par match la position géométrique de son équipe au moment des temps forts, quand l'équipe se montre offensive, s'ouvre des occasions et marque des buts.
- Le tacticien a également la capacité d'analyser le comportement de son équipe en fonction de la réaction de l'équipe concurrente. Ces données peuvent ensuite être agrégées avec d'autres sources telles que l'historique des matchs joués ou les données recueillies pendant les entraînements.



BIG DATA: Généralités

- **Cas d'utilisation : Sécurité publique (1/2)**

- Aujourd'hui, avec le Big Data, la vidéosurveillance va beaucoup plus loin : elle permet d'analyser automatiquement les images et les situations, de croiser les informations, et d'envoyer des alertes.
- Cette analyse de vidéo avancée est utilisée en particulier pour :
 - la sécurité du trafic (routier, ferroviaire, maritime et aérien)
 - la protection des espaces et des bâtiments publics
 - la sécurité personnelle.
- Il est aujourd'hui possible à travers l'analyse des images vidéo de faire de :
 - la reconnaissance d'objets et de mouvements
 - la lecture de plaques minéralogiques
 - la détection de véhicule non autorisé
 - la reconnaissance faciale
 - l'auto-surveillance avec possibilité de déclenchement d'alertes ou autres actions automatisées.

BIG DATA: Généralités

- **Cas d'utilisation : Sécurité publique (2/2)**



- A titre d'exemple la ville de Londres avait, quant à elle, mis en place un système de reconnaissance faciale lors des jeux olympiques de 2012 organisés dans la capitale, afin de lutter contre le terrorisme pour lequel l'alerte était à son maximum.

BIG DATA: Acteurs et Solutions

- Les grands acteurs du web tel que **Google, Yahoo, Facebook, Twitter, LinkedIn** ... ont été les premiers à être confrontés à des volumétries de données extrêmement importantes et ont été à l'origine des premières innovations en la matière portées principalement sur deux types de technologies :



1. Les plateformes de développement et de traitement des données (GFS, Hadoop, Spark,...) [chapitre 2-3-4]

2. Les bases de données (NoSql) [chapitre 5-6]

BIG DATA: Historique

- **Historique : Big Data, Google : Le système de fichier GFS**



- Pour stocker son index grandissant quelle solution pour Google ?

1. Utilisation d'un SGBDR ?

- Problème de distribution des données
- Problème du nombre d'utilisateurs
- Problème de Vitesse du moteur de recherche




2. Invention d'un nouveau système propriétaire : GFS (Google File Système) en 2003



BIG DATA: Historique

- Historique : Big Data, Google : Le système de fichier GFS



BIG DATA: Historique

- **Historique : Big Data, Comment exploiter ce système de fichier ?**



- La notion de Big Data est intimement lié à la capacité de traitements de gros volumes.
 - **Le premier Article a été publié en 2004 : Jeffrey Dean and Sanjay Ghemawat**
 - **MapReduce : Simplified Data Processing on Large Clusters**
 - **C'est un algorithme inventé par Google, Inc afin de distribuer des traitements sur un ensemble de machines avec le système GFS.**
 - **Google possède aujourd'hui plus de 1 000 000 de serveurs interconnectés dans le monde.**

BIG DATA: Les Acteurs de l'Open Source

- Les contributeurs de l'implémentation Libre et Open Source :

YAHOO!

facebook

Linked in

twitter

- Ces entreprises ont décidé d'ouvrir leurs développements internes au monde Open Source.
- Un certain nombre de ces technologies comme « **Hadoop** » et « **Spark** » font partie de la fondation Apache et ont été intégrés aux offres de « **Big Data** » des grands acteurs tel que **IBM**, **Oracle**, **Microsoft**, **EMC** ...

BIG DATA: Plateforme – Technologies - Outils

Société	Technologie développée	Type de technologie
Google	Big Table	Système de base de données distribuée propriétaire reposant sur GFS (Google File System). Technologie non Open Source, mais qui a inspiré Hbase qui est Open Source.
	MapReduce	Plate-forme de développement pour traitements distribués
Yahoo	Hadoop	Plateforme Java destinée aux applications distribuées et à la gestion intensive des données. Issue à l'origine de GFS et MapReduce.
	S4	Plateforme de développement dédiée aux applications de traitement continu de flux de données.
Facebook	Cassandra	Base de données de type NoSQL et distribuée.
	Hive	Logiciel d'analyse de données utilisant Hadoop.
Twitter	Storm	Plateforme de traitement de données massives.
	FockDB	Base de données distribuée de type graphe.
LinkedIn	SenseiDB	Base de données temps réel distribuée et semi-structurée.
	Voldemort	Base de données distribuée destinée aux très grosses volumétries.

Tableau : Quelques technologies Open Source du Big Data

BIG DATA: Plateforme – Technologies - Outils


- Processing
 - Hadoop, Hive, Pig, mrjob, Caffeine
- NoSQL Databases
 - Hbase, MongoDB, Vertica, Cassandra, Neo4j, etc.
- Servers
 - EC2, Google App Engine, Elastic, Beanstalk, Heroku
- Analytics
 - R, SAS, Python scikit-learn, Spark MLlib, Apache Mahout
- Search
 - Solr/Lucene, Elasticsearch

BIG DATA: Plateforme – Technologies - Outils



BIG DATA Landscape (1/3)


Big Data Landscape



BIG DATA Landscape (2/3)

BIG DATA LANDSCAPE, VERSION 3.0

Exited: Acquisition or IPO



BIG DATA Landscape (3/3)

BIG DATA LANDSCAPE 2017



Big Data ?!

Souleymane DIALLO DBA / Développeur full-Stack
622-56-62-82 / 654-49-29-20

Activer